


AI大模型应用：NLP与大模型

2025/2026年


内部资料，请勿外传

RAG流程




RAG检索与排序


- ✓ Dense Vector主要处理语义匹配问题，而Sparse Vector可以处理精确匹配问题
- ✓ 提供统一向量化模型针对同一文本同时产出Dense向量和Sparse向量
- ✓ 召回阶段提供Dense索引+Sparse索引结合的混合检索



RAG工程实现



RAG工程实现



RAG工程实现

- ✓ 原文引用
- ✓ 原文跳转

你好，我是智能行政助手

我是你的智能行政助手，集成全网搜索结果，为你提供更加权威可信的回答

你可以试着问我：

公司的晋升制度是怎样的

出差什么情况可以乘坐飞机

帮我写一封邮件，宣传公司最新保密制度

如何 出差 报销？

公司 出差 酒店标准是怎样的？

公司 出差 交通工具是怎样的？

知识范围 ▼ 出差

Powered By ZHIPU-AI

目前机器人已经学会了人事相关的招聘管理、入职指引、行为规范、考勤制度、销售激励、晋升发展、离职管理相关知识。提问最好以问句形式，否则我可能不理解这个问题。

人事制度机器人

没打卡怎么办

如果您没有打卡，您需要在当月考勤周期内完成补卡审批全流程。每人每月有 5 次补卡机会，超过 5 次以上的部分按缺勤计算。当月考勤周期未打卡又未完成补卡审批全流程，且没有请假记录的，相应天数按旷工计。

以上内容为 AI 生成，不代表开发立场，请勿删除或修改本标记

引用知识

杭州办公设备新人须知.pdf p1 p2

ZP-RL-003-考勤管理制度-V1.1 - 20230609更... p4 p5

行政补充知识.xlsx-Sheet1 第32行 第41行 第42行 更多

知识范围 ▼ 可问我人事相关问题，提问最好以问句形式，否则我可能不理解这

ZP-RL-003-考勤管理制度-V1.1 - 20230609更新.pdf

<

5

>

×

北京智谱华章科技有限公司 ZP-RL-003-考勤管理制度
V2.1
界面上打卡；远程办公可在飞书手机端上“外勤打卡”，并说明远程办公原因。

5、迟到、早退

迟到或早退 30-60 分钟，每合计 3 次按半天缺勤计算；迟到或早退 60-180 分钟，每次按缺勤 0.5 天计算；迟到或早退 180 分钟以上，按缺勤 1 天计算。

6、补卡：每月补卡机会

请在当月考勤周期内完成补卡审批全流程，每人每月有 5 次补卡机会，超过 5 次以上的部分按缺勤计算。当月考勤周期未打卡又未完成补卡审批全流程，且没有请假记录的，相应天数按旷工计。

7、旷工、旷工

7.1 旷工：正常工作日员工不请假未出勤、请假未获批准而未出勤，未按要求擅自远程办公的均按旷工计。

7.2 旷工旷工情况下，扣除当天的工资；如因旷工给公司造成经济损失的，公司有权要求员工弥补相应的损失，连续旷工 3 天或一年内累计旷工 5 天（含）以上的，视为严重违反公司的规章制度，公司有权立即与其解除劳动合同关系，且不支付经济补偿。

8、因公外出申请

员工因工作原因需要因公外出（不离开本市），应提前至少 0.5 天在飞书填报因公外出申请，并写明外出开始时间、外出结束时间、外出地点、外出事由，经审批通过后，方可外出，直接主管、隔级主管、部门负责人对下属员工的公出有监督、审核、管理的责任和权力。

RAG工程实现

精答

- 三级标题以下的知识点，直接可回答
 - 直接可答
 - 场景问题，推理可答
- 三级标题以下知识点，内容相关不能直接回答问题，给出相关的知识

【问题】拆迁安置住房要提供哪些材料？

【知识】

（五）购买拆迁安置住房提取

1、办理条件

XXXXXX

2、办理要件

（1）身份证件原件（居民身份证或台湾居民来往内地通行证或港澳居民来往内地通行证）.....

【答案】

您好,如果您因购买拆迁安置房需要提取公积金,需要以下材料:

1. 身份证件原件（居民身份证或台湾居民来往内地通行证或港澳居民来往内地通行证）
2. 拆迁协议原件.....

请您准备好以上材料,前往公积金中心或指定的提取银行网点办理提取业务。如有其他问题,请随时联系我们,我们将竭诚为您服务。

拒答

- 无关话题拒答，闲聊的
- 包含部分知识可答
- 完全不包含拒答
 - 业务区域错误
- 包含知识，业务要求拒答
 - 操作类/查询类/计算类/对比类/原因类

【问题】 提取承诺书无法下载

【知识】六、其他提取业务

（一）公积金提取附则

（二）法院扣划

（三）提取查询

（四）可线上办理提取情形

【答案】根据苏州公积金政策业务逻辑，用户的提问属于操作类问题，因为用户询问的是提取承诺书无法下载的问题，这属于在APP、微信公众号、单位及个人网上营业厅、小程序、支付宝等移动端及互联网端业务操作中遇到的问题。根据业务逻辑，这类问题属于拒答类型，因此我无法回答用户的问题。

反问

- 一级二级知识点，需要反问

【问题】买卖住房提取可以不

【知识】

一、购房提取

（1）购买新房提取 ...

（2）购买二手房提取 ...

（3）购买公有住房产权提取 ...

.....

【答案】


尊敬的用户，您好！关于您提到的买卖住房提取公积金的问题，根据我国相关政策，购买住房是可以提取公积金的。具体的提取条件和流程会根据您所购买的房型有所不同。目前，我们支持以下几种购房提取方式：

1. 购买新房提取
2. 购买二手房提取
3. 购买公有住房产权提取

.....

RAG工程实现

- 高质量内容加工：基于深度文档理解。自动识别文档的布局，包括标题、段落、换行等，包含图片和表格
- 模版文本处理：多种文本处理模版，不同文本内容定制化处理，处理可控准确，应对对复杂多变的数据。
- 兼容各类异构数据源：支持丰富的文件类型： Word 文档、PPT、EXECL 表格、TXT 文件、PDF、结构化数据。





RAG难点：文档解析方法





Documents

Document Parsing & Chunking



RAG难点：数据切分方法

- ✓ 固定大小：设置100个字符为一个chunk
 - ✓ 滑动窗口：在固定大小的情况下 加入 overlap
 - ✓ 按照文档结构：先划分为段落，再划分为句子
 - ✓ 递归分块：先划分章节、再划分段落、句子
-
- ✓ 语义分块：将含义相近的句子划分到一个chunk
 - ✓ 大模型分块：写一个提示词，让大模型分块；
 - ✓ Late chunking：提取token特征，对chunk tokens进行pooling；





RAG难点：数据切分方法

层次切分




多粒度切分




RAG难点：Query预处理方法

- ✓ 引导进行二次提问、引导到已知的提问；
- ✓ Query Rewriting（查询重写）：将用户的提问改写一下，转换多个提问；
- ✓ Step-Back Strategy（后退一步策略）：让大模型生成一个更加抽象、更加基础的问题
- ✓ Hypothetical Document Embeddings (HyDE)
- ✓ 拒绝回答、特定格式回答；



Hypothetical Document Embeddings





大模型部署工具：ollama

Ollama 是一个开源工具，用于在本地便捷地部署和运行大型语言模型（LLMs），如 Llama 3、DeepSeek-R1、Mistral 等。它简化了本地运行大模型的过程，并提供命令行、REST API 和 WebUI 支持。

- ✓ 支持离线使用，数据无需上传云端。支持量化模型，使消费级设备（如 8GB 内存的笔记本）也能运行
- ✓ 支持多并发和加载多个模型，还可以结合其他工具，如 LM Studio 或 Text Generation WebUI，来更方便地管理和运行多个模型
- ✓ 相比云端推理框架（如 vLLM），吞吐量和并发能力较弱，不适合高负载生产环境

Download Ollama



Install with one command:

```
curl -fsSL https://ollama.com/install.sh | sh
```





[View script source](#) • [Manual install instructions](#)

大模型部署工具：vllm

vLLM是一款专为大语言模型(LLM)推理加速而设计的框架，实现了KV缓存内存几乎零浪费，解决了内存管理瓶颈问题。


- ✓ 与FlashAttention和FlashInfer的集成，加速注意力计算。支持GPU张量并行，支持分布式推理
- ✓ 兼容多种主流量化方法，INT4量化可将7B模型显存需求从14GB压缩至4GB，精度损失<1%
- ✓ 相比HuggingFace Transformers，吞吐量提升高达24倍；
- ✓ 相比Text Generation Inference(TGI)，吞吐量高出3.5倍10；
- ✓ 在高并发场景下，吞吐量可达传统框架的5-10倍



大模型部署工具：sglang

SGLang采用独特的前后端协同设计理念，将高效的运行时系统与灵活的控制语言相结合，为大语言模型应用提供了一套完整的解决方案。

- ✓ **多轮对话系统**：利用状态管理和KV缓存复用技术，高效处理对话历史，减少冗余计算
- ✓ **结构化数据生成**：通过X-Grammar系统生成严格符合语法规则的JSON、XML等结构化输出
- ✓ **复杂推理任务**：支持思维链(Chain-of-Thought)和思维树(Tree-of-Thought)等高级推理技术，便于实现多步骤问题求解




非关系型数据库

关系型数据库（SQL）依据“一对一、一对多、多对多”的关系模型创建数据库，并将数据以二维表格的形式储存，各个表之间建立关系，通过这些关联的表格间分类、合并、连接或选取等运算来实现数据的管理。


非关系型数据库（NoSQL）按存储方式分为向量数据库、图形数据库、文档存储数据库、宽列数据库、键值存储数据库等，能够实现非结构化或半结构化数据的处理和存储。

SQL




Relational


NoSQL




Key-Value



Column Store



Graph



Document

非关系型数据库

数据库类型	数据模型	主要特点	代表性产品
文档存储数据库	JSON/XML文档	灵活的文档结构，适合复杂数据	ElasticSearch
列存储数据库	列族	高效存储稀疏数据，适合大规模数据	Cassandra
图数据库	图结构（节点和边）	适合复杂关系数据的存储和查询	Neo4j
时间序列数据库	时间序列数据	高效存储和查询时间序列数据	InfluxDB
向量数据库	高维向量	高效的相似性搜索，适合嵌入向量	FAISS/Milvus

没有固定的表结构、数据之间不存在表与表之间的关系、数据之间可以是独立的、NoSQL可用于分布式系统上。

Elasticsearch

Elasticsearch (ES) 是一个开源的、分布式搜索和分析引擎，它是Elastic Stack的核心组成部分，被广泛应用于各种需要快速、可扩展地进行数据存储、搜索和分析的场景。

- ✓ **分布式和可扩展性：** Elasticsearch能够将数据分散存储在多个节点上，从而实现水平扩展，轻松处理PB级别的数据量。
- ✓ **实时搜索和分析：** Elasticsearch能够实时索引和存储各种类型的数据（结构化、非结构化、向量数据），并提供强大的全文检索、过滤查询、聚合分析等功能，帮助用户快速获取洞察。
- ✓ **向量数据库功能：** Elasticsearch可以处理文本、图像等多模态向量，实现更智能、更相关的搜索结果。

Relation Databases

- Database
- Table
- Row
- Column
- Schema



Elasticsearch

Index

Type

Document


Fields

Mapping

向量数据库

向量数据库是一种专门用于**存储和查询向量数据**的数据库系统。向量数据库支持对向量数据进行各种操作：

- ✓ **向量检索**：根据给定的向量，找出数据库中与之最相似的向量，例如在图像向量数据库中，用户输入一张图片进行搜索时，
- ✓ 先将这张图片转换为一个向量，通过向量之间的近似检索，找到与输入图片最相似的图片。
- ✓ **向量聚类**：根据给定的相似度度量，将数据库中的向量分类，例如根据图片的内容或风格，将图片分成不同的主题。
- ✓ **向量降维**：根据给定的目标维度，将数据库中的高维向量转换成低维向量，以便于可视化或压缩存储。
- ✓ **向量计算**：根据给定的算法或模型，对数据库中的向量进行计算或分析，例如根据神经网络模型，对图片进行分类或标注。




向量数据库

特性	传统关系型数据库	向量数据库
数据类型	数值、字符串、时间等传统数据类型	向量数据，不存储原始数据
数据规模	大，按照库、表和行	中等
数据组织方式	基于表格，按照行和列组织	基于向量，按照向量维度组织
查找方式	精确查找：点查/范围查	近似查找
低时延，高并发	是	中等
下游应用场景	元信息存储	非结构化数据检索

向量数据库

向量数据库在建表时，需指定向量的索引类型（如 HNSW 等）与 相似度计算方法。数据库存储的向量将会按照指定的索引类 型进行索引。在向量检索时，便会依据索引并使用已选择的相似性计算方法进行匹配，快速高效地获取目标向量。如果不指定索引类型，向量数据库将默认进行暴力搜索。



- ✓ **高维**：向量数据通常有很多元素，维度很高
- ✓ **稀疏**：向量数据中很多元素的值可能为零或接近零。
- ✓ **异构**：向量数据中的元素可能有不同的类型或含义。
- ✓ **动态**：向量数据可能随着时间或环境变化而变化。


向量检索

各种向量数据库提供不同的相似性计算方法，但对于文本，最常用的两种度量是：

- ✓ 余弦距离产生一个规范化的值（介于 -1 和 1 之间）
- ✓ 欧氏距离是计算两个向量之间的直线距离

两种不同的检索方式，它们针对不同的需求和应用场景：


- ✓ 精确检索 (Exact Retrieval)：精确地找到与查询完全匹配的文档或数据项。
- ✓ 近似检索 (Approximate Retrieval)：返回与查询相似数据项，通过权衡精度和效率来提高搜索速度。



近似检索：LSH

局部敏感哈希（Locality Sensitive Hashing）是一种使用近似最近邻搜索的索引技术。它的特点是快速，同时仍然提供一个近似、非穷举的结果。


LSH 使用一组哈希函数将相似向量映射到“桶”中，从而使相似向量具有相同的哈希值。这样，就可以通过比较哈希值来判断向量之间的相似度。



近似检索：KD Tree

Kd-Tree (K-dimensional tree) 是一棵二叉树，树中存储的是一些K维数据。在一个K维数据集上构建一棵Kd-Tree代表了对该K维数据集构成的K维空间的一个划分，即树中的每个结点就对应了一个K维的超矩形区域。


- 1.递归构建左右子树：对切分元素左边的数据和右边的数据分别递归构建KD树的左子树和右子树。
- 2.定位查询点的叶子节点：从根节点开始，根据查询点的各维坐标值，递归地沿着树分支向下寻找，直到到达叶子节点。



近似检索：K-Means

保存向量数据后，先对向量数据先进行K-Means聚类，划定了 N 个聚类中心，然后将每个向量分配到最近的聚类中心，经过聚类算法不断调整聚类中心位置，就可以将向量数据分成 M 个簇。每次搜索时，只需要先判断搜索向量属于哪个簇，然后再在这一个簇中进行搜索。

关键点：如何确定聚类个数？




近似检索：Product Quantization (PQ)

Product Quantization (PQ) 是一种用于降低高维向量存储和搜索复杂度的技术。它通过将高维向量划分为多个低维子向量，然后在每个子向量上进行独立的聚类，以减少码本的大小，从而降低内存占用和提高搜索速度。


- 1.向量分解：** 将原始高维向量分解为多个低维子向量。
- 2.独立聚类：** 对每个子向量进行独立的聚类，生成子码本。
- 3.编码：** 将原始向量的每个子向量编码为对应的子码本中的索引。

在搜索时，将每个子向量的编码值组合成原始向量的近似编码，通过在子码本中查找得到近似的最近邻。



向量数据库


IVF-PQ: 倒排索引和乘积量化



近似检索：Hierarchical Navigable Small Worlds (HNSW)

Hierarchical Navigable Small Worlds (HNSW) 是一种用于近似最近邻搜索的算法，它通过构建多层的图结构来提高搜索效率。HNSW 算法具有较高的搜索质量和速度，特别适用于大规模高维向量数据集。

- 1.图结构： 将向量空间划分为多个层级，每个层级构建一个小世界图 (Small World Graph) 。
- 2.节点连接： 在每个小世界图中，每个节点与其最近邻的一些节点相连接，形成一个局部连通的结构。
- 3.多层结构： 高层的图结构具有更大的边缘长度，适用于快速搜索，而低层的图结构具有较小的边缘长度，适用于准确搜索。
- 4.搜索过程： 在搜索时，从最高层的图开始，通过快速搜索逐渐降低到低层的图，以保证搜索的效率和准确性。



开发环境：FastAPI

